Tech Summit 2018

Hands-on lab

使用 Azure ML 以及 Batch AI 分布式模型训练

Microsoft

目录

总览

微软 Azure Machine Learning 服务是一款可用于开发和部署机器学习模型的云服务。 使用 Azure 机器学习服务，你可以在生成、培训、部署和管理模型时对其进行跟踪，所有这些都以云提供的广泛规模完成。Azure 机器学习服务提供了一个基于云的环境，你可以使用这一环境来开发、培训、测试、部署、管理和跟踪机器学习模型。

Azure 机器学习服务完全支持开放源代码技术，因此，你可以使用数以万计的开放源代码 Python 包与机器学习组件（如 TensorFlow 和 scikit-learn）。 借助丰富的工具（如 Jupyter Notebook 或 Visual Studio Code Tools for AI），可以交互式地轻松探索数据、转换数据，然后开发和测试模型。 此外，Azure 机器学习服务还包括自动化模型生成和优化的功能，能够帮助你轻松、高效和准确地创建模型。

使用 Azure 机器学习服务，你可以先在本地计算机上开始培训，然后扩大到云。 通过提供对 Azure Batch AI 的本机支持和高级超参数优化服务，你可以使用云的强大功能更快地生成更好的模型。

实验目的

本次实验覆盖以下内容:

- 配置 AzureML Notebook 所需环境
- 通过 AzureML 进行本地训练
- 通过 AzureML 使用 BatchAI 群集进行云端分布式训练

系统需求

本次实验需要:

- Windows 10
- Anaconda 及 Python3.6 环境

- AzureML Python SDK
- Github AzureML Notebook 样本

设置

如果您使用的是大会提供的实验设备，请跳过此节。如果您使用自己的设备，请进行以下设置以进行本次实验:

1. 安装 Microsoft Windows 10.
2. 安装 Anaconda 及 Python3.6 环境.
3. 在 Anaconda 中安装 AzureML Python SDK：pip install azureml-sdk[notebooks]

   详见 https://docs.microsoft.com/zh-cn/azure/machine-learning/service/quickstart-create-workspace-with-python
4. 安装 Git 环境

本实验所需时间为 40 分钟。

Part 1: 配置 AzureML Notebook 所需环境

Task 1 –下载本实验相关 AzureML 样本，启动 Notebook Server

首先，我们需要从 Github 上将本实验相关的 AzureML 样本下载在本地目录（https://github.com/Azure/MachineLearningNotebooks）

1. 在桌面点击""anaconda prompt"，选择对应的程序打开一个新的 Anaconda 终端

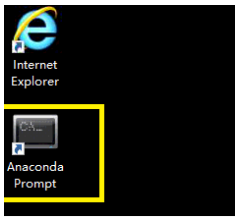

2. 输入 git clone https://github.com/lliimsft/MachineLearningNotebooks.git
3. 进入目录 cd MachineLearningNotebooks
4. 在目录内通过 jupyter notebook 开起本地的 Notebook Server

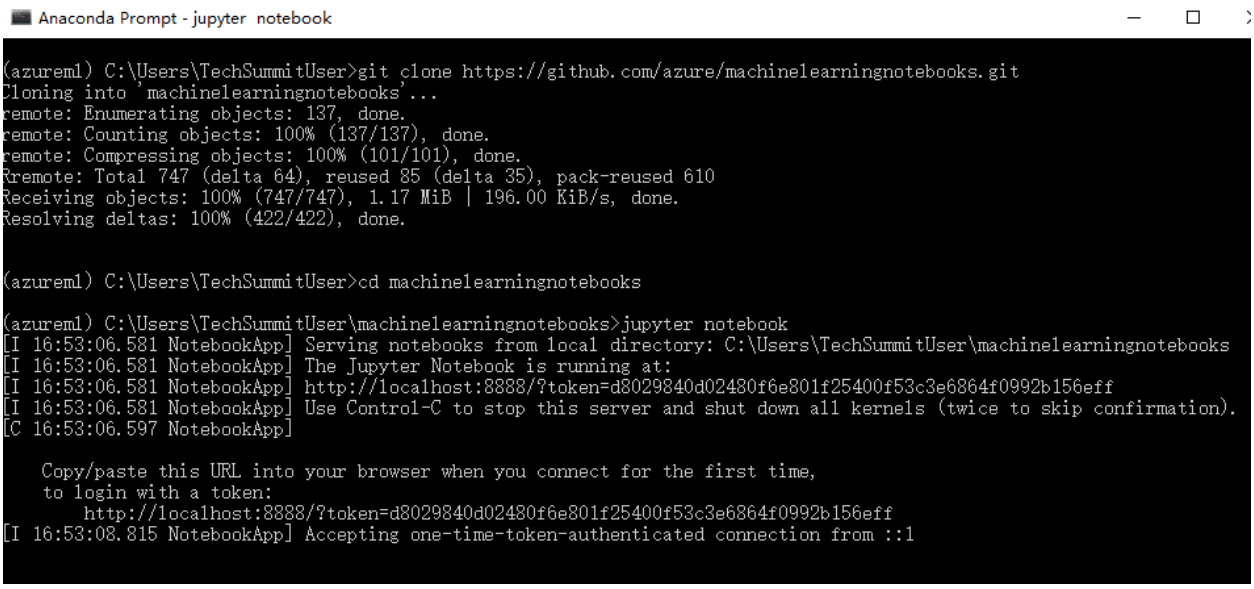

Task 2 – 在本地创建 Azure ML Notebook 运行所需的配置文件

1. 在弹出的 Jupyter notebook 主窗口中，点击进入 0.configuration.ipynb。通过运行这个 Jupyter 脚本，我们将配置本地的 notebook library，并创建一个新的 Azure Machine Learning workspace

2. 请选择默认的 Python3 Kernel。

3. 运行第一个 Cell 查看目前所使用的 AzureML SDK 版本

```
In [1]: import azureml.core

        print("SDK Version:", azureml.core.VERSION)

        SDK Version: 0.1.65
```

4. 在第二个 Cell 里，填入本实验所使用的 Azure 订阅号，并输入希望创建的 Azure 资源组名及 AzureML Workspace 名称。注意，请尽量使用唯一性较强的 Azure 资源组名，以避免冲突。运行期间浏览器将会弹出互动式登入的提示，请输入你的 Azure 账号相关信息进行登录。

```
In [3]: from azureml.core import Workspace

        subscription_id ='[redacted]'
        resource_group ='my_hol_rg'
        workspace_name = 'my_first_workspace'

        try:
           ws = Workspace(subscription_id = subscription_id, resource_group = resource_group, workspace_name = workspace_name)
           ws.write_config()
           print('Workspace configuration succeeded. You are all set!')
        except:
           print('Workspace not found. Run the cells below.')

        get_workspace error using subscription_id=029ee373-e6af-40bb-9776-fbade18e8669, resource_group_name=my_hol_rg, workspace_na
        me=my_first_workspace

        Workspace not found. Run the cells below.
```

5. 运行接下三个 Cells 创建 Azure 资源组和 AzureML Workspace，并生成本地配置文件。

```
In [3]: workspace_region = "eastus2"

In [4]: import os

        subscription_id = os.environ.get("SUBSCRIPTION_ID", subscription_id)
        resource_group = os.environ.get("RESOURCE_GROUP", resource_group)
        workspace_name = os.environ.get("WORKSPACE_NAME", workspace_name)
        workspace_region = os.environ.get("WORKSPACE_REGION", workspace_region)

In [5]: # import the Workspace class and check the azureml SDK version
        from azureml.core import Workspace

        ws = Workspace.create(name = workspace_name,
                              subscription_id = subscription_id,
                              resource_group = resource_group,
                              location = workspace_region,
                              create_resource_group = True,
                              exist_ok = True)
        ws.get_details()
        ws.write_config()

        UserWarning: The resource group doesn't exist or was not provided. AzureML SDK is creating a resource group=my_hol_rg in lo
        cation=eastus2 using subscription=029ee373-e6af-40bb-9776-fbade18e8669.

        Wrote the config file config.json to: C:\Users\Li\Documents\MachineLearningNotebooks\aml_config\config.json
```

Task 3 – 通过 Azure Portal 查找 AzureML 相关资源

执行完成之前步骤后，对应的 AzureML Workspace 应该已经创建成功。这时，我们可以登入 Azure Portal 查看刚刚创建好的 Workspace。

1. 登入你的 Azure Portal 账户，在左上角所有服务选项中，搜索“Machine Learning Service Workspaces”。

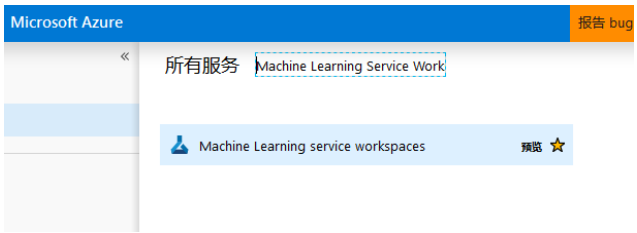

2. 在显示的列表中，你将可以找到刚才创建好的 workspace。

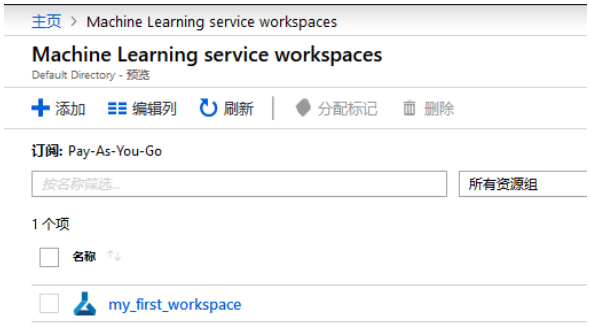

用户可以通过 AzureML Workspace 的 Portal 界面查看并管理模型训练的实验(Experiments)以及运算对象(Compute)。在创建 Workspace 时候自动，系统也会自动为用户创建一个 Azure 存储账号及容器注册表，用来存放训练实验相关的文件及 Docker 镜像。

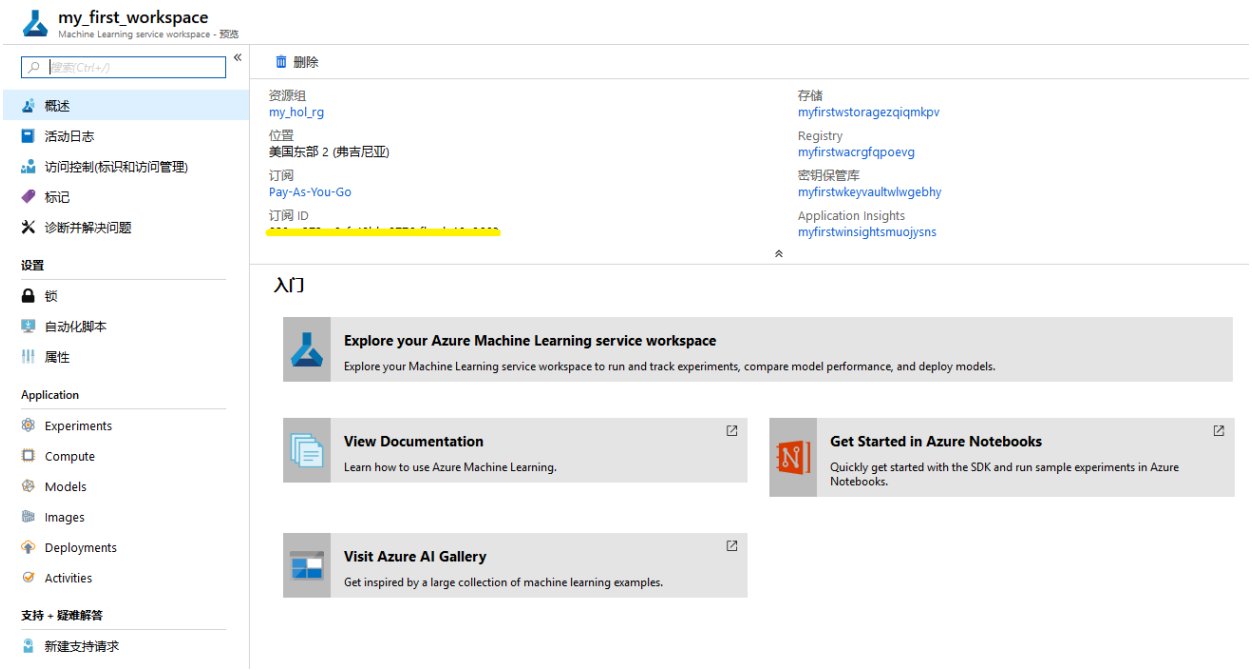

Part 2: 通过 AzureML 进行本地训练

作为 AI 开发平台，AzureML 支持用户在本地或 Azure 云端进行模型训练及相关资源的管理。用户需要提供自己的 Python 训练脚本及所需的配置环境。在这一部分，我们将介绍如何通过 AzureML 在客户端本地进行训练。

Task 1 – 进入 Notebook 文件并初始化 Workspace 及训练实验

1. 回到 Notebook 主界面，进入并打开./ 01.getting-started/02.train-on-local/ 02.train-on-local.ipynb
2. 运行第一个 Cell 检查 AzueML SDK 版本。再运行第二个 Cell 载入之前生成的配置文件，获取订阅号，数据中心，资源组及 Workspace 相关信息。
3. 运行第三个 Cell 在本地创建 AzureML 实验对象，命名为"train-on-local"。

Task 2 – 预览训练脚本

1. 本节实验将使用 AzureML 的示例脚本"train.py"进行一个简单的回归模型训练。
2. 运行第四个及第五个 Cell 查看训练脚本。

View `train.py`

`train.py` is already created for you.

In [4]:
```
with open('./train.py', 'r') as f:
    print(f.read())
```

```
# Copyright (c) Microsoft. All rights reserved.
# Licensed under the MIT license.

from sklearn.datasets import load_diabetes
from sklearn.linear_model import Ridge
from sklearn.metrics import mean_squared_error
from sklearn.model_selection import train_test_split
from azureml.core.run import Run
from sklearn.externals import joblib
import os
import numpy as np
import mylib

os.makedirs('./outputs', exist_ok=True)

X, y = load_diabetes(return_X_y=True)

run = Run.get_submitted_run()
```

Note `train.py` also references a `mylib.py` file.

In [5]:
```
with open('./mylib.py', 'r') as f:
    print(f.read())
```

```
# Copyright (c) Microsoft. All rights reserved.
# Licensed under the MIT license.

import numpy as np


def get_alphas():
    # list of numbers from 0.0 to 1.0 with a 0.05 interval
    return np.arange(0.0, 1.0, 0.05)
```

Task 3 – 提交训练作业进行本地训练

AzureML 支持三种本地训练环境：

- *User-managed*：在当前用户管理的 Python 环境中进行作业。
- *System-managed*：由 AzureML 在本地创建一个新的 Python 虚拟环境，安装所需的 Package 库进行训练。
- *Docker-based*：由 AzureML 创建本次训练所需的 Docker 镜像，在本地开启容器进行作业。此模式需要本机已经安装好并启动 Docker 引擎。

本节实验我们使用 *System-managed* 环境配置脚本所需的"scikit-learn"库

1. 找到"System-managed environment"小节，运行以下 Cell 定义训练环境，命名为"*run_config_system_managed*"

```
In [6]: from azureml.core.runconfig import RunConfiguration
        from azureml.core.conda_dependencies import CondaDependencies

        run_config_system_managed = RunConfiguration()

        run_config_system_managed.environment.python.user_managed_dependencies = False
        run_config_system_managed.prepare_environment = True

        # Specify conda dependencies with scikit-learn
        cd = CondaDependencies.create(conda_packages=['scikit-learn'])
        run_config_system_managed.environment.python.conda_dependencies = cd
```

2. 定义当前路径为作业源目录，定义"train.py"为训练脚本，并提交作业。

```
In [7]: from azureml.core import ScriptRunConfig

        src = ScriptRunConfig(source_directory="./", script='train.py', run_config=run_config_system_managed)
        run = exp.submit(src)
```

3. 运行接下来的两个 Cell，我们可以看到提交的作业正处于"Preparing"状态，表示 AzureML 正在配置训练环境，并安装所需的 Python 库。我们可以在 Notebook 里刷新作业状态，并实时查看作业日志。

```
In [8]: run
```

Out[8]:

Experiment	Id	Type	Status	Details Page	Docs Page
train-on-local	train-on-local_1538979019_9ab32c75	azureml.scriptrun	Preparing	Link to Azure Portal	Link to Documentation

Block and wait till run finishes.

```
In [*]: run.wait_for_completion(show_output = True)
RunId: train-on-local_1538979019_9ab32c75

Streaming azureml-logs/60_control_log.txt
=========================================

Streaming log file azureml-logs/60_control_log.txt
Running ['conda', '--version']
Creating Conda environment...
Logging experiment preparation status in history service.
Solving environment: ...working... done

Downloading and Extracting Packages
python-3.6.2         | 17.1 MB   | ########## | 100%
scikit-learn-0.20.0  | 5.2 MB    | ########## | 100%
numpy-base-1.15.2    | 3.9 MB    | ########## | 100%
numpy-1.15.2         | 48 KB     | ########## | 100%
mkl_fft-1.0.6        | 120 KB    | ########## | 100%
mkl_random-1.0.1     | 268 KB    | ########## | 100%
scipy-1.1.0          | 13.6 MB   | ########## | 100%
Preparing transaction: ...working... done
```

4. 与此同时，我们可以在 Portal 的 Experiments 中查找刚刚创建的实验。并发现状态正处于 Preparing 的作业。

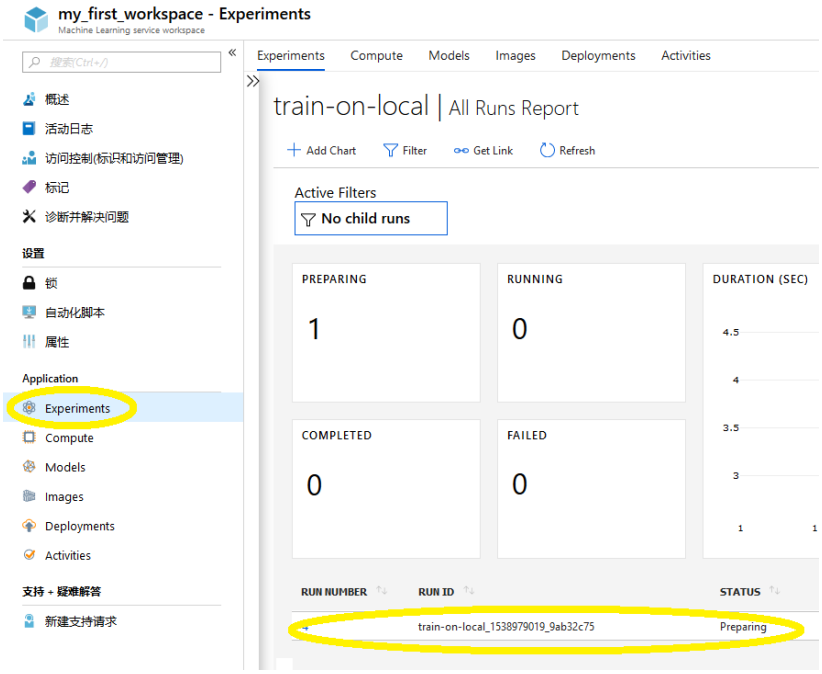

5. 点击进入作业中，可在 Logs 页面实时查看作业日志。当训练环境配置完成时，作业将自动进入 Running 阶段。最终，作业状态将变为 Completed，表示训练已成功完成。

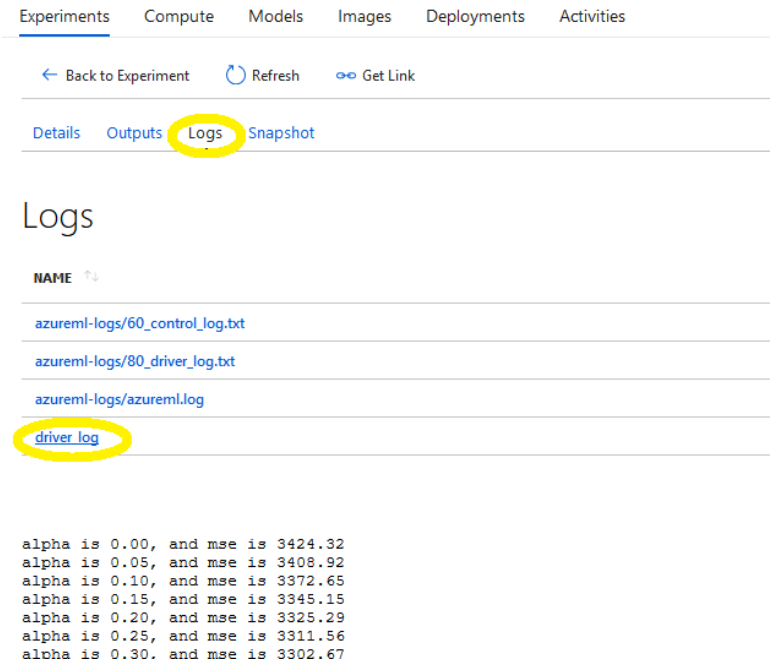

Part 3: 通过 AzureML 使用 BatchAI 群集进行分布式训练

在这一部分，我们将介绍如何通过 AzureML 在 Azure 服务器端进行分布式 Tensorflow 训练。. 在这个例子里，我们将创建一个自动伸缩的 BatchAI 虚拟机群集，并将这个群集里作为计算对象进行基于 MNIST 手写数据的神经网络模型训练。

Task 1 – 进入 Notebook 文件并初始化 Workspace

1. 回到 Notebook 主界面，进入并打开 training/05.distributed-tensorflow-with-parameter-server/05.distributed-tensorflow-with-parameter-server.ipynb
2. 运行第一个 Cell 检查 AzueML SDK 版本。再运行第二个 Cell 载入之前生成的配置文件，获取订阅号，数据中心，资源组及 Workspace 相关信息。

```
In [2]: from azureml.core.workspace import Workspace

        ws = Workspace.from_config()
        print('Workspace name: ' + ws.name,
              'Azure region: ' + ws.location,
              'Subscription id: ' + ws.subscription_id,
              'Resource group: ' + ws.resource_group, sep = '\n')

Found the config file in: C:\Users\llii\MachineLearningNotebooks\aml_config\config.json
Workspace name: my_first_workspace
Azure region: eastus2
Subscription id: 1cba1da6-5a83-45e1-a88e-8b397eb84356
Resource group: llii_hol_10_25
```

Task 2 – 创建 BatchAI 虚拟机群集作为运算对象

在第三个 Cell 中，我们将创建一个 BatchAI 虚拟机群集，并将其作为我们模型训练的计算对象：

- 请将 BatchAI 群集命名为“cpucluster”
- 将群集的虚机类型设置为“STANDARD_D2_v2”，即每台虚机配有两块 CPU

- 我们启动 BatchAI 群集的自动伸缩功能，规定此群集的最小虚机数为 0 台，最大虚机数为 4 台：当有训练作业被提交时，群集将自动分配新的虚机进行训练，当所有任务完成后，群集也将自动释放闲置的虚机以节约资源。
- 如果该名称的 BatchAI 群集已存在，我们将使用已有资源。反之，将创建一个新的群集。

```
In [3]: from azureml.core.compute import ComputeTarget, BatchAiCompute
        from azureml.core.compute_target import ComputeTargetException

        # choose a name for your cluster
        cluster_name = "cpucluster"

        try:
            compute_target = ComputeTarget(workspace=ws, name=cluster_name)
            print('Found existing compute target.')
        except ComputeTargetException:
            print('Creating a new compute target...')
            compute_config = BatchAiCompute.provisioning_configuration(vm_size='STANDARD_D2_v2',
                                                                       autoscale_enabled=True,
                                                                       cluster_min_nodes=0,
                                                                       cluster_max_nodes=4)

            # create the cluster
            compute_target = ComputeTarget.create(ws, cluster_name, compute_config)

            compute_target.wait_for_completion(show_output=True)

            # Use the 'status' property to get a detailed status for the current cluster.
            print(compute_target.status.serialize())

Creating a new compute target...
Creating
succeeded
BatchAI wait for completion finished
Minimum number of nodes requested have been provisioned
{'allocationState': 'steady', 'allocationStateTransitionTime': '2018-10-10T06:17:44.763000+00:00', 'creationTime': '2018-10
-10T06:17:34.853000+00:00', 'currentNodeCount': 0, 'errors': None, 'nodeStateCounts': {'idleNodeCount': 0, 'leavingNodeCoun
t': 0, 'preparingNodeCount': 0, 'runningNodeCount': 0, 'unusableNodeCount': 0}, 'provisioningState': 'succeeded', 'provisio
ningStateTransitionTime': '2018-10-10T06:17:44.152000+00:00', 'scaleSettings': {'manual': None, 'autoScale': {'maximumNodeC
ount': 4, 'minimumNodeCount': 0, 'initialNodeCount': 0}}, 'vmPriority': 'dedicated', 'vmSize': 'STANDARD_D2_V2'}
```

当 BatchAI 群集创建成功，我们可以在 Portal 中点击 Workspace 目录下的“Compute”，检查该群集的各项属性。

Task 3 – 创建本地源目录并放入训练脚本

此次训练，我们将使用 AzureML 提供的 Tensorflow 训练脚本（https://github.com/Azure/MachineLearningNotebooks/blob/master/training/05.distributed-tensorflow-with-parameter-server/tf_mnist_replica.py）。

这个脚本使用基于 parameter server 分布式训练框架，并将自动下载所需的 MNIST 训练数据。

我们在本地创建一个名为“tf-distr-ps”的文件夹作为此次训练的目录，将脚本文件放入此目录中。

```
In [4]: import os

        project_folder = './tf-distr-ps'
        os.makedirs(project_folder, exist_ok=True)
```

Copy the training script `tf_mnist_replica.py` into this project directory.

```
In [5]: import shutil
        shutil.copy('tf_mnist_replica.py', project_folder)

Out[5]: './tf-distr-ps\\tf_mnist_replica.py'
```

Task 4 – 定义实验及分布式 Tensorflow 作业

1. 我们将此次实验命名为"tf-distr-ps"。

```
In [6]: from azureml.core import Experiment

        experiment_name = 'tf-distr-ps'
        experiment = Experiment(ws, name=experiment_name)
```

2. 下一步，我们将给出此次训练任务的具体定义：
   a. 定义此次训练任务的 estimator 使用 Tensorflow 框架
   b. 使用刚才创建的 BatchAI 群集作为计算对象
   c. 通过"script_params"定义训练脚本的参数：我们设置每个 worker 的 GPU 数改为 0
   d. 设置此次训练将使用 2 台虚拟机
   e. 在"distributed_backend"将分布式模块设置为"ps"，即 parameter server，并将 worker 数跟 ps 数分别设置为 2 和 1。这样一来，我们将在两台虚机上分别启动一个 worker，每个 worker 占用一块 CPU
   f. 因为本作业不使用 GPU，将 use_gpu 设置为 False

```
In [8]: from azureml.train.dnn import TensorFlow

        script_params={
            '--num_gpus': 0,
            '--train_steps' : 1000
        }

        estimator = TensorFlow(source_directory=project_folder,
                               compute_target=compute_target,
                               script_params=script_params,
                               entry_script='tf_mnist_replica.py',
                               node_count=2,
                               worker_count=2,
                               parameter_server_count=1,
                               distributed_backend='ps',
                               use_gpu=False)
```

Task 5 – 提交并监督训练作业

运行接下来的 Cell 提交训练作业至 AzureML 服务器。

Submit job

Run your experiment by submitting your estimator object. Note that this call is asynchronous.

```
In [9]: run = experiment.submit(estimator)
        print(run.get_details())
```


```
{'runId': 'tf-distr-ps_1538980408142', 'target': 'gpucluster', 'status': 'Preparing', 'properties': {'azureml.runsource': '
experiment', 'ContentSnapshotId': '005ec762-be3a-4db6-aa28-cc426a489658'}, 'runDefinition': {'Script': 'tf_mnist_replica.py
', 'Arguments': ['--num_gpus', '1', '--train_steps', '10000'], 'Framework': 3, 'Target': 'gpucluster', 'DataReferences': {}
, 'JobName': None, 'AutoPrepareEnvironment': True, 'MaxRunDurationSeconds': None, 'Environment': {'Python': {'InterpreterPa
th': 'python', 'UserManagedDependencies': False, 'CondaDependencies': {'name': 'project_environment', 'dependencies': ['pyt
hon=3.6.2', {'pip': ['azureml-defaults']}, 'tensorflow-gpu=1.9.0']}, 'CondaDependenciesFile': None}, 'EnvironmentVariables'
: {'EXAMPLE_ENV_VAR': 'EXAMPLE_VALUE', 'NCCL_SOCKET_IFNAME': '^docker0'}, 'Docker': {'BaseImage': 'mcr.microsoft.com/azurem
l/base-gpu:0.1.3', 'Enabled': True, 'SharedVolumes': True, 'GpuSupport': True, 'Arguments': [], 'BaseImageRegistry': {'Addr
ess': None, 'Username': None, 'Password': None}}, 'Spark': {'Repositories': ['https://mmlspark.azureedge.net/maven'], 'Pack
ages': [{'Group': 'com.microsoft.ml.spark', 'Artifact': 'mmlspark_2.11', 'Version': '0.12'}], 'PrecachePackages': True}}, '
History': {'OutputCollection': True}, 'Spark': {'Configuration': {'spark.app.name': 'Azure ML Experiment', 'spark.yarn.maxA
ppAttempts': '1'}}, 'BatchAi': {'NodeCount': 2}, 'Tensorflow': {'WorkerCount': 2, 'ParameterServerCount': 1}, 'Mpi': {'Proc
essCountPerNode': 1}, 'Hdi': {'YarnDeployMode': 2}, 'ContainerInstance': {'Region': None, 'CpuCores': 1, 'MemoryGb': 4}, 'E
xposedPorts': None, 'PrepareEnvironment': None}, 'logFiles': {'azureml-logs/20_image_build_log.txt': 'https://myfirstwstora
gezqiqmkpv.blob.core.windows.net/azureml/ExperimentRun/tf-distr-ps_1538980408142/azureml-logs/20_image_build_log.txt?sv=201
7-04-17&sr=b&sig=neJ3wSjAzeeeT1tbjP48WejqiGS1mmm45BCtxj%2Bv8Yo%3D&st=2018-10-08T06%3A23%3A32Z&se=2018-10-08T14%3A33%3A32Z&s
p=r'}}
```


与本地实验类似，我们可以留在 Notebook 实时监管任务进度。同时也可以在 Portal 的 Experiments 中查找刚刚创建的实验。

若作业创建成功，我们可以并发现一个正在 Preparing 的作业（run）。

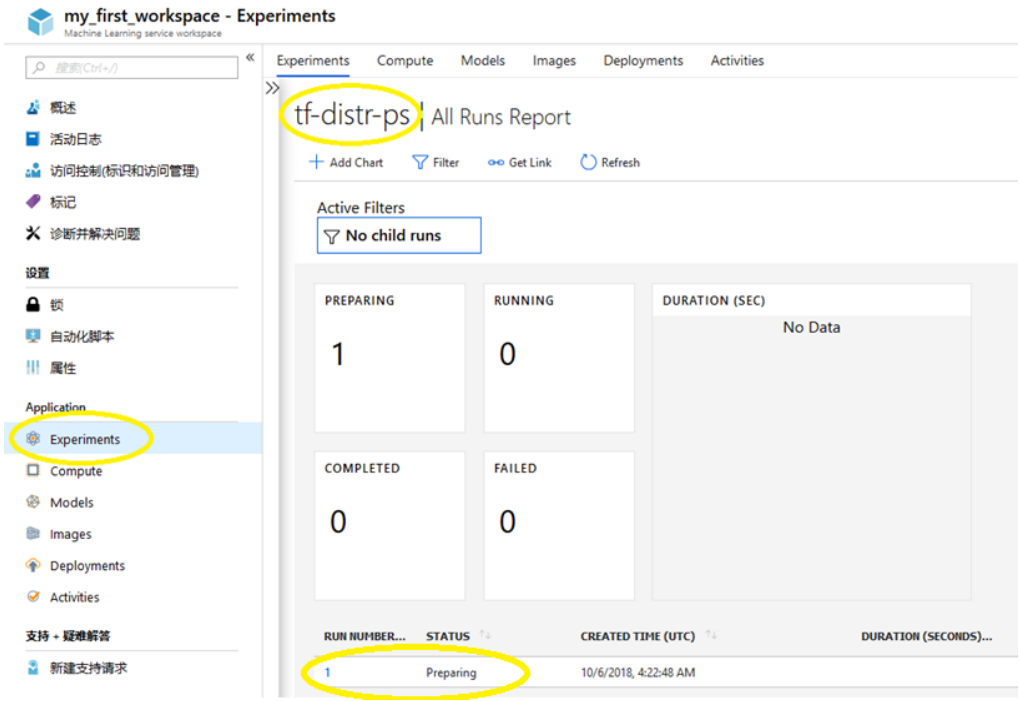

当作业处于 Preparing 状态的时候，AzureML 正在创建适用于本次训练作业的 docker 镜像，包括 Tensorflow 运行环境及相关 Packages。我们可以在 portal 页面点进这一作业，在"Logs"栏中点击"azureml-logs/20_image_build_log.txt"可以实时查看镜像创建的日志。

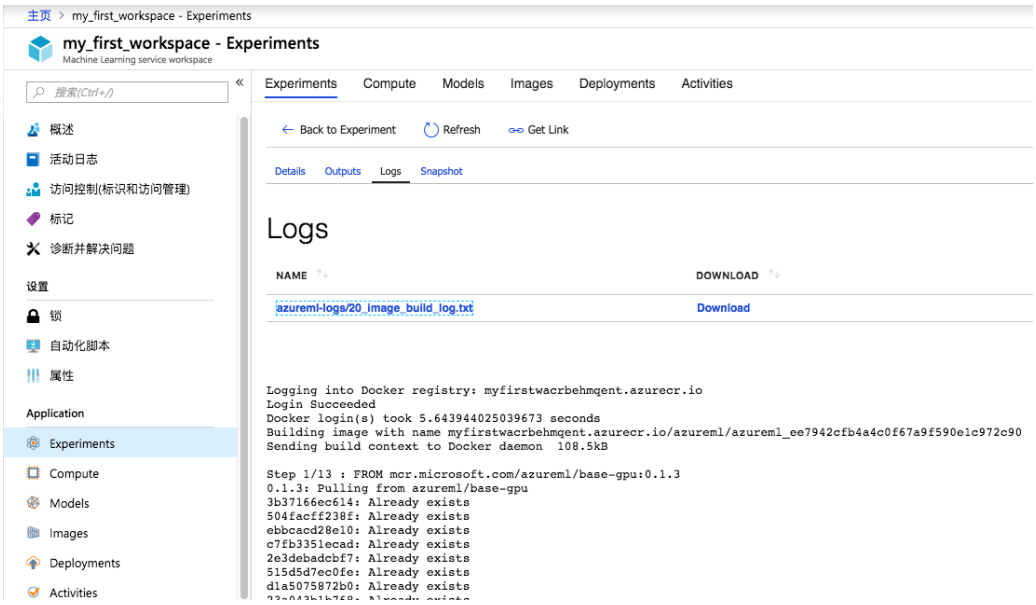

Docker 镜像创建大约需要不到 10 分钟的时间，创建好的镜像将被存入 Workspace 附属的容器注册表中，以便今后同类作业使用。

之后，训练作业将从 Preparing 状态进入 Running 状态， BatchAI 群集此时将自动申请 2 台新的虚拟机。虚拟机分配及配置过程大约需要 3 至 4 分钟，完成后训练作业将正式开始执行。

我们同样可以通过实时日志的方式追踪作业进程。刷新 Portal 界面直到更多日志文件的出现。我们可以点击查看"azureml-logs/80_driver_log_worker_0.txt"的内容，这个文件即是 worker 0 的训练日志。同理，"azureml-logs/80_driver_log_worker_1.txt"为 worker 1 的训练日志。

当训练成功完成，作业状态将变为"Completed"。如有错误发生，作业状态会变为"Failed"，可以通过检查日志的方式进行排查。

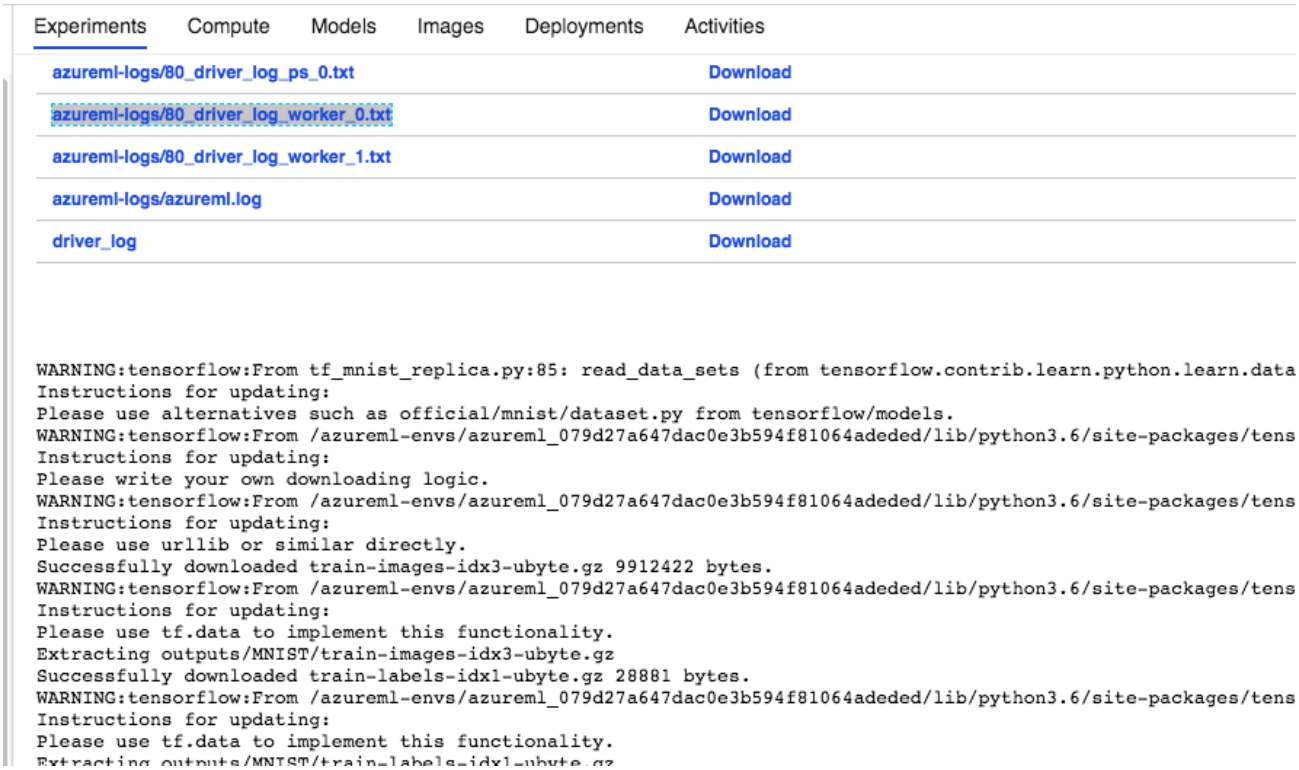

同样的，我们也可以在 notebook 端使用 Jupyter widget 插件追踪作业进程，查看虚机状态及日志文件：

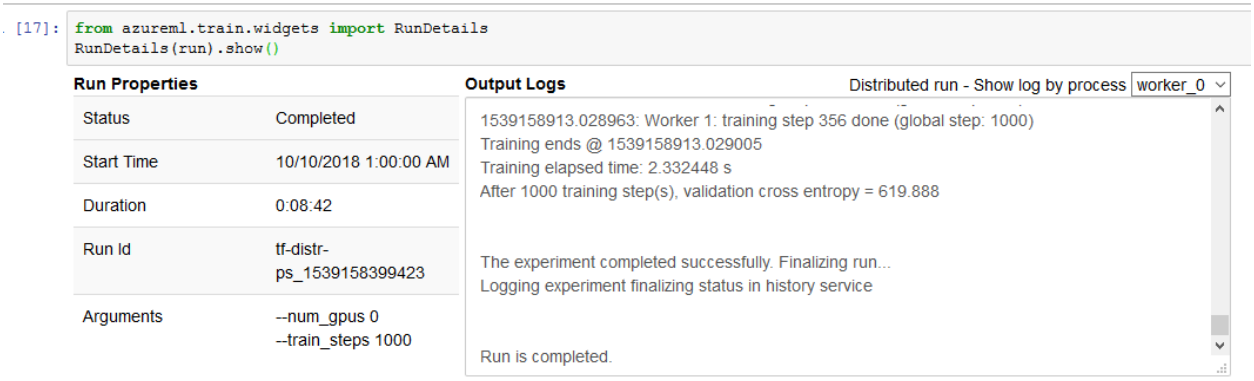

以上为本实验的所有内容，感谢您的参与！